



HafenCity University Hamburg

University Of The Built Environment And Metropolitan Development

**Seminar GIT**

## **Location Based Service**

Study program:

**Geodesy and Geoinformatics**

Matriculation number:

**6059167 und 6056745**

Professor:

**Prof. Dr.-Ing. Jochen Schiewe**

Group 3:

**Sumit Kaur und Simeon Zeyse**

July 12, 2022

---

## Contents

<b>1</b>	<b>Einleitung</b>	<b>1</b>
<b>2</b>	<b>Methodologie</b>	<b>1</b>
2.1	Das dynamischer Kalman Filter . . . . .	1
2.1.1	Diskreter Kalman-Filter (lineares Modell) . . . . .	1
2.1.2	Extended Kalmanfilter (nicht- lineares Modell) . . . . .	3
2.1.3	Weitere Quellen: . . . . .	4
2.2	Weigted Least-Square . . . . .	4
<b>3</b>	<b>Ergebnisse</b>	<b>5</b>
3.1	Weighted-Least-Square . . . . .	5
<b>4</b>	<b>Herausforderungen</b>	<b>5</b>
<b>5</b>	<b>Fazit und Ausblick</b>	<b>5</b>
	<b>Bibliography</b>	<b>6</b>

# 1 Einleitung

Leitfrage: **Wie unterscheiden sich die Ergebnisse einer Ausgleichung von ?Personal Dead Reckoning? mittels Kalman-Filter und Least-Squares Methode?**

Einführung in das Thema, einschließlich der Problemstellung und ähnlicher Arbeiten.

# 2 Methodologie

Erläuterung der Methoden in der Theorie und des allgemeinen Konzepts für diejenigen, die bereits bestehende Konzepte, Algorithmen, Methoden, etc. verwendet haben.

## 2.1 Das dynamischer Kalman Filter

Eicker:

Ein Kalman Filter findet dort Anwendung, wo bestimmte Sensoren nicht funktionieren oder sogar ausfallen und man dennoch die Systemgrößen schätzen möchte. Dafür setzt sich das dynamische Kalman Filter aus einem Beobachtungsmodell und einem Bewegungsmodell zusammen. Bei dem Beobachtungsmodell handelt es sich um Beobachtungen und ihre Unsicherheiten. Bei dem Bewegungsmodell spricht wird auch von einer Prädiktion (dynamisches Modell) und ihren Unsicherheiten gesprochen. Aus ihr erfolgt dann die Schätzung des Zustandes.

### 2.1.1 Diskreter Kalman-Filter (lineares Modell)

Bei dem diskreten Kalman-Filter ist die Idee die Beobachtungen zu bestimmten (diskreten) Zeitpunkten mit einem Bewegungsmodell zu kombinieren. Das Bewegungsmodell prädiziert dann den Zustandsvektor ausgehend von der Schätzung des vorherigen Schrittes. Generell werden vier Schritte benötigt: die Prädiktion, die Innovation, die Kalman-Gain-Matrix und das Update.

Das generelle Beobachtungsmodell sieht wie folgt aus:

$$l_{i+1} = A_{i+1}x_{i+1} + e_{i+1}, \quad (2.1)$$

mit  $l$  = Beobachtungen/Messungen,  $A$  = Designmatrix,  $x$  = unbekannte Parameter und  $e$  = Residuen (Beobachtungsrauschen). Die Designmatrix beinhaltet die partiellen Ableitungen der Beobachtungsgleichungen nach den Parametern. Bei den Residuen handelt es sich um die negierten Verbesserungen. Sie sind normalverteilt mit einem Erwartungswert von 0.

Das hier verwendete Bewegungsmodell sieht wie folgt aus:

$$x_{i+1} = T_i x_i + C_i w_i, \quad (2.2)$$

mit  $T$  = Transitionsmatrix (prädiziert Bewegung von einem Zeitpunkt zum nächsten),  $w$  = Störgröße (Unsicherheit im Bewegungsmodell: Rauschen),  $C$  = Störgrößenmatrix (Auswirkung dieser Unsicherheit auf die Prädiktion des Zustandes). Da wir annehmen, dass die Unsicherheiten im Bewegungsmodell ausreichend von den Varianzen der geschätzten Parameter abgedeckt werden, wird die Formel 2.2 durch die folgende Formeln ersetzt:

$$x_{i+1} = T_i x_i. \quad (2.3)$$

1. Prädiktion: Welche Trajektorie des Fahrzeugs sagt das Bewegungsmodell voraus?

In der Prädiktion wird der aktuelle Schritt mit den Daten des vorherigen Schrittes und der Transitionsmatrix berechnet. Die Transitionsmatrix beinhaltet die partiellen Ableitungen der prädizierten Größen nach den Schätzungen des vorigen Schrittes. Die zugehörige Kovarianzmatrix wird mit Hilfe des Varianzfortpflanzungsgesetzes berechnet.

$$\bar{x}_{i+1} = T_i + \hat{x}_i \quad (2.4)$$

$$\sum(\bar{x}_{i+1}) = T_i \sum(\hat{x}_i) T_i^T + C_i \sum(w_i) C_i^T \quad (2.5)$$

2. Innovation: Welche Trajektorie des Fahrzeugs sagt das Bewegungsmodell voraus? Was behaupten die Beobachtungen? Wie sehr weichen die Beobachtungen von der Prädiktion ab?  
=> Innovation

In dem 2. Schritt der Innovation wird die Differenz der Prädiktion zu den Beobachtungen berechnet und auch hier wird mit Hilfe des VFGs die Kovarianzmatrix gerechnet

$X_{5G}$  und  $Y_{5G}$ ,  $\Delta x_i$  und  $\Delta y_i$  = Differenz zwischen der aufsummierten schrittänge, und schrittrichtung.

$$\mathbf{d}_{i+1} = \mathbf{l}_{i+1} - \mathbf{A}_{i+1} \bar{\mathbf{x}}_{i+1} \quad (2.6)$$

$$\sum(\mathbf{d}_{i+1}) = \sum(\mathbf{l}_{i+1}) + \mathbf{A}_{i+1} \sum(\bar{\mathbf{x}}_{i+1}) \mathbf{A}_{i+1}^T \quad (2.7)$$

Dann folgt die Berechnung der Kalman Gain Matrix, die in dem Update die Innovation gewichtet. Die zugehörige Kov.matrix des Updates wird auch wieder mit dem VFG berechnet.

3. Gain Matrix (K-Matrix): Relative Gewichtung von Prädiktion und Beobachtungen anhand der jeweiligen Genauigkeiten

Kalman Gain Matrix setzt sich aus den Kov.Matrizen der prädiktion und der innovation zusammen. Je genauer die Kov matrix der innovation ist desto mehr gewicht erhalten die

$$\mathbf{K}_{i+1} = \sum(\bar{\mathbf{x}}_{i+1}) \mathbf{A}_{i+1}^T \sum^{-1}(\mathbf{d}_{i+1}) \quad (2.8)$$

4. Update:

Gewichtetes Mittel aus Prädiktion und Innovation

$$\hat{\mathbf{x}}_{i+1} = \bar{\mathbf{x}}_{i+1} + \mathbf{K}_{i+1} \mathbf{d}_{i+1} \quad (2.9)$$

$$\sum(\hat{\mathbf{x}}_{i+1}) = [\mathbf{I} - \mathbf{K}_{i+1} \mathbf{A}_{i+1}] \sum(\bar{\mathbf{x}}_{i+1}) \quad (2.10)$$

Geschichte des Kalman-Filters:

Erdunfen von Rudolf E. Kalman (Transcations of the ASME-Journal of Basic Engineering, 82 (Series D): 35-45.Copyright by ASME)

Gut geeignet, um die Bahnen von Raketen zu berechnen (der Apollo Mondmission)

Dynamisches Modell: Trajektorie der Mondrakete Beobachtungen: Space sextant, inertial navigator (Weltraumsextant, Trägheitsnavigator)

### 2.1.2 Extended Kalmanfilter (nicht- lineares Modell)

Weder Bewegungsmodell noch das Beobachtungsmodell ist linear, deshalb wird das extended Kalman Filter gebraucht.

Neues Bewegungsmodell:

$$\mathbf{x}_{i+1} = \mathbf{f}_i^{i+1}(\mathbf{x}_i, \mathbf{w}_i) \quad (2.11)$$

$$\mathbf{l}_{i+1} = \mathbf{a}_{i+1}(\mathbf{x}_{i+1}) + \mathbf{e}_{i+1} \quad (2.12)$$

Bei nicht-linearen Zusammenhängen werden die Matrizen A, T und C durch Linearisierung (partielle Ableitungen) der nicht-linearen Funktionen f und a bestimmt:

$$\mathbf{T}_i = \left. \frac{\partial \mathbf{f}_i^{i+1}(\mathbf{x}_i, \mathbf{w}_i)}{\partial \mathbf{x}_i} \right|_{\mathbf{x}_i = \hat{\mathbf{x}}_i} \quad (2.13)$$

$$\mathbf{C}_i = \left. \frac{\partial \mathbf{f}_i^{i+1}(\mathbf{x}_i, \mathbf{w}_i)}{\partial \mathbf{w}_i} \right|_{\mathbf{w}_i} \quad (2.14)$$

$$\mathbf{A}_{i+1} = \left. \frac{\partial \mathbf{a}_{i+1}(\mathbf{x}_{i+1})}{\partial \mathbf{x}_{i+1}} \right|_{\mathbf{x}_{i+1} = \bar{\mathbf{x}}_{i+1}} \quad (2.15)$$

### 2.1.3 Weitere Quellen:

<https://www.cbcity.de/das-kalman-filter-einfach-erklart-teil-2>

## 2.2 Weighted Least-Square

Weighted Least-Square basiert auf der Grundlage der Methode der kleinsten Quadrate. Dabei werden die Parameter so gewählt, dass die Quadratsumme der Verbesserungen möglichst klein ist.

$$|\mathbf{v}|^2 = \sum_{i=1}^n v_i^2 \rightarrow \min \quad (2.16)$$

$$l + v = Ax \text{ mit } \sum(l) = \sigma_0^2 P^{-1} \quad (2.17)$$

Wobei die linke Gleichung das funktionale Modell repräsentiert, in dem der funktionale Zusammenhang zwischen Beobachtungen und Unbekannten steckt. Die rechte Gleichung nennt sich auch das stochastische Modell und dient der Beschreibung der Messunsicherheit bzw. zur Einführung von Gewichten für die Beobachtungen. Dafür wird die Gewichtsmatrix  $P$  eingeführt.

Schätzung der unbekannten Parameter:

$$\hat{x} = (A^T P A)^{-1} A^T P l \quad (2.18)$$

### 3 Implementation

Detaillierte Ausführung der Arbeitsschritte einschließlich der Ergebnisse bei verschiedenen Implementierungsparametern.

#### 3.1 Weighted-Least-Square

Für jeden Durchgang eine weitere Schleife: 5G faken, indem delta x und delta y auf Koordinaten addieren, welche die PDR Werte , solange bis zur nächsten 5G Koordinate.

Genauigkeit:

s1 (absolut, 5G): 3 s2 (relativ, PDR): 0.2

### 4 Fazit und Ausblick

Eine Erörterung (oder "Bewertung") der Ergebnisse, Zusammenfassung und zukünftige Forschungsperspektiven

## Bibliography

- Aladag, E. (2014). An evaluation of geographic information systems in social studies lessons: Teachers' views. *Educational Sciences: Theory and Practice*, 14(4), 1533–1539.
- Strachan, C., & Mitchell, J. (2014). Teachers' perceptions of esri story maps as effective teaching tools. *Review of International Geographical Education Online*, 4, 195–220.
- Egiebor, E. E., & Foster, E. J. (2019). Students' perceptions of their engagement using gis-story maps. *Journal of Geography*, 118(2), 51–65. <https://doi.org/10.1080/00221341.2018.1515975>
- Kerski, J. J. (2015). Geo-awareness, geo-enablement, geotechnologies, citizen science, and storytelling: Geography on the world stage. *Geography compass*, 9(1), 14–26.
- Roth, R. E. (2021). Cartographic design as visual storytelling: Synthesis and review of map-based narratives, genres, and tropes. *The Cartographic Journal*, 58(1), 83–114. <https://doi.org/10.1080/00087041.2019.1633103>