



HafenCity University Hamburg

University Of The Built Environment And Metropolitan Development

Seminar GIT

Topic 1: Story Maps

Study program:

Geodesy and Geoinformatics

Matriculation number:

6059167 und 6056745

Professor:

Prof. Dr.-Ing. Jochen Schiewe

Group 3:

Sumit Kaur und Simeon Zeyse

June 27, 2022

Contents

1	Einleitung	1
2	Methoden	1
2.1	Das dynamischer Kalman Filter	1
2.1.1	Diskreter Kalman-Filter (lineares Modell)	1
2.1.2	Extended Kalmanfilter (nicht- lineares Modell)	3
2.1.3	Weitere Quellen:	3
2.2	Weigted Least-Square	4
3	Ergebnisse	5
4	Herausforderungen	5
5	Fazit und Ausblick	5
	Bibliography	6

1 Einleitung

2 Methoden

2.1 Das dynamischer Kalman Filter

Eicker:

Ein Kalman Filter findet dort Anwendung, wo bestimmte Sensoren nicht funktionieren oder sogar ausfallen und man dennoch die Systemgrößen schätzen möchte. Dafür setzt sich das dynamische Kalman Filter aus einem Beobachtungsmodell und einem Bewegungsmodell zusammen. Bei dem Beobachtungsmodell handelt es sich um Beobachtungen und ihre Unsicherheiten. Bei dem Bewegungsmodell spricht wird auch von einer Prädiktion (dynamisches Modell) und ihren Unsicherheiten gesprochen. Aus ihr erfolgt dann die Schätzung des Zustandes.

2.1.1 Diskreter Kalman-Filter (lineares Modell)

Bei dem diskreten Kalman-Filter ist die Idee die Beobachtungen zu bestimmten (diskreten) Zeitpunkten mit einem Bewegungsmodell zu kombinieren. Das Bewegungsmodell prädiziert dann den Zustandsvektor ausgehend von der Schätzung des vorherigen Schrittes. Generell werden vier Schritte benötigt: die Prädiktion, die Innovation, die Kalman-Gain-Matrix und das Update.

Das generelle Beobachtungsmodell sieht wie folgt aus:

$$l_{i+1} = A_{i+1}x_{i+1} + e_{i+1}, \quad (2.1)$$

mit l = Beobachtungen/Messungen, A = Designmatrix, x = unbekannte Parameter und e = Residuen (Beobachtungsrauschen). Die Designmatrix beinhaltet die partiellen Ableitungen der Beobachtungsgleichungen nach den Parametern. Bei den Residuen handelt es sich um die negierten Verbesserungen. Sie sind normalverteilt mit einem Erwartungswert von 0.

Das hier verwendete Bewegungsmodell sieht wie folgt aus:

$$x_{i+1} = T_i x_i + C_i w_i, \quad (2.2)$$

mit T = Transitionsmatrix (prädiziert Bewegung von einem zum nächsten Zeitpunkt), w = Störgröße (Unsicherheit im Bewegungsmodell: Rauschen), C = Störgrößenmatrix (Auswirkung dieser Unsicherheit auf die Prädiktion des Zustandes). Da wir annehmen, dass die Unsicherheiten im Bewegungsmodell ausreichend von den Varianzen der geschätzten Parameter abgedeckt werden, wird die Formel 2.2 durch die folgende Formeln ersetzt:

$$x_{i+1} = T_i x_i, \quad (2.3)$$

Störgröße normalverteilt, Erwartungswert = 0 -> beeinflusst nur das stochastisches Modell aber nicht die eigentliche Prädiktion

1. Prädiktion:

Welche Trajektorie des Fahrzeugs sagt das Bewegungsmodell voraus?

$$\bar{x}_{i+1} = T_i + \hat{x}_i$$

$$\sum(\bar{x}_{i+1}) = T_i \sum(\hat{x}_i) T_i^T + C_i \sum(w_i) C_i^T$$

2. Innovation:

Welche Trajektorie des Fahrzeugs sagt das Bewegungsmodell voraus? Was behaupten die Beobachtungen? Wie sehr weichen die Beobachtungen von der Prädiktion ab? => Innovation

$$d_{i+1} = l_{i+1} - A_{i+1} \bar{x}_{i+1}$$

$$\sum(d_{i+1}) = \sum(l_{i+1}) + A_{i+1} \sum(\bar{x}_{i+1}) A_{i+1}^T$$

3. Gain Matrix (K-Matrix):

Relative Gewichtung von Prädiktion und Beobachtungen anhand der jeweiligen Genauigkeiten

$$K_{i+1} = \sum(\bar{x}_{i+1}) A_{i+1}^T \sum^{-1}(d_{i+1})$$

4. Update:

Gewichtetes Mittel aus Prädiktion und Innovation

$$\hat{x}_{i+1} = \bar{x}_{i+1} + K_{i+1} d_{i+1}$$

$$\sum(\hat{x}_{i+1}) = [I - K_{i+1} A_{i+1}] \sum(\bar{x}_{i+1})$$

Geschichte des Kalman-Filters:

Erdunfen von Rudolf E. Kalman (Transcations of the ASME-Journal of Basic Engineering, 82 (Series D): 35-45. Copyright by ASME)

Gut geeignet, um die Bahnen von Raketen zu berechnen (der Apollo Mondmission)

Dynamisches Modell: Trajektorie der Mondrakete Beobachtungen: Space sextant, inertial navigator (Weltraumsextant, Trägheitsnavigator)

2.1.2 Extended Kalmanfilter (nicht- lineares Modell)

Weder Bewegungsmodell noch das Beobachtungsmodell ist linear, deshalb wird das extended Kalman Filter gebraucht.

$$x_{i+1} = f_i^{i+1}(x_i, w_i)$$

$$l_{i+1} = a_{i+1}(x_{i+1}) + e_{i+1}$$

Bei nicht-linearen Zusammenhängen werden die Matrizen A, T und C durch Linearisierung (partielle Ableitungen) der nicht-linearen Funktionen f und a bestimmt:

$$\mathbf{T} = \frac{\partial f(x, w)}{\partial x} \quad (2.4)$$

$$\mathbf{C} = \frac{\partial f(x, w)}{\partial w} \quad (2.5)$$

$$\mathbf{A} = \frac{\partial a(x)}{\partial x} \quad (2.6)$$

Input:

$$x_{i+1} = f_i^{i+1}(x_i, w_i)$$

2.1.3 Weitere Quellen:

<https://www.cbcity.de/das-kalman-filter-einfach-erklart-teil-2>

2.2 Weighted Least-Square

Weighted Least-Square basiert auf der Grundlage der Methode der kleinsten Quadrate. Dabei werden die Parameter so gewählt, dass die Quadratsumme der Verbesserungen möglichst klein ist.

$$|v|^2 = \sum_{i=1}^n v_i^2 \rightarrow \min \quad (2.7)$$

$$l + v = Ax \text{ mit } \sum(l) = \sigma_0^2 P^{-1} \quad (2.8)$$

Wobei die linke Gleichung das funktionale Modell repräsentiert, in dem der funktionale Zusammenhang zwischen Beobachtungen und Unbekannten steckt. Die rechte Gleichung nennt sich auch das stochastische Modell und dient der Beschreibung der Messunsicherheit bzw. zur Einführung von Gewichten für die Beobachtungen. Dafür wird die Gewichtsmatrix P eingeführt.

Schätzung der unbekannten Parameter:

$$\hat{x} = (A^T P A)^{-1} A^T P l \quad (2.9)$$


Wiederholung: Ausgleichung mit gewichteten Beobachtungen		HCU HafenCity Universität Hamburg
Gauss-Markov-Modell $l + v = Ax \text{ mit } \Sigma(l) = \sigma_0^2 P^{-1}$	Schätzung der unbekannten Parameter: $\hat{x} = (A^T P A)^{-1} A^T P l$	
Quadratsumme der Residuen $v^T P v = (Ax - l)^T P (Ax - l)$		
Die Minimierung der Quadratsumme der Residuen $\frac{\partial}{\partial x} (v^T P v) = 0$ führt auf die folgenden Normalgleichungen (Herleitung an der Tafel): $A^T P A x = A^T P l$		

Figure 2.1

3 Ergebnisse

4 Herausforderungen

5 Fazit und Ausblick

Bibliography

- Aladag, E. (2014). An evaluation of geographic information systems in social studies lessons: Teachers' views. *Educational Sciences: Theory and Practice*, 14(4), 1533–1539.
- Strachan, C., & Mitchell, J. (2014). Teachers' perceptions of esri story maps as effective teaching tools. *Review of International Geographical Education Online*, 4, 195–220.
- Egiebor, E. E., & Foster, E. J. (2019). Students' perceptions of their engagement using gis-story maps. *Journal of Geography*, 118(2), 51–65. <https://doi.org/10.1080/00221341.2018.1515975>
- Kerski, J. J. (2015). Geo-awareness, geo-enablement, geotechnologies, citizen science, and storytelling: Geography on the world stage. *Geography compass*, 9(1), 14–26.
- Roth, R. E. (2021). Cartographic design as visual storytelling: Synthesis and review of map-based narratives, genres, and tropes. *The Cartographic Journal*, 58(1), 83–114. <https://doi.org/10.1080/00087041.2019.1633103>